

Thực nghiệm đánh giá truy hồi bằng chứng

Fact-checking pipeline

Mục tiêu đánh giá

- Đánh giá khả năng truy hồi top-3 bằng chứng cho mỗi claim trong `FinalDataset/claims_merged.csv`.
- So sánh các cấu hình truy hồi theo bốn yếu tố:
 - mô hình refine claim: Gemini 2.5 Flash và GPT-4o mini;
 - collection Qdrant: `fixed_size` và `semantic`;
 - vector ảnh: CLIP gốc và CLIP fine-tuned;
 - reranker: tắt hoặc bật.
- Kết quả được xuất ra tại `database/retrieval_eval_outputs/`.

Dữ liệu

- Ground truth: `claims_merged.csv`
- Số claim khớp để eval: **1293**
- Gold evidence:
 - URL/text evidence
 - đường dẫn image evidence

Mô hình

- Text dense embedding:
`bkai-foundation-models/
vietnamese-bi-encoder`
- Image/text CLIP:
`sentence-transformers/
clip-ViT-B-32`
- CLIP fine-tuned:
`models/clip-vit-b32-
finetuned-final-final/best`
- Cross-encoder reranker:
`namdp-ptit/ViRanker`

Ma trận thí nghiệm

Yếu tố	Giá trị thử nghiệm
Refiner	gemini-2.5-flash, gpt4o_mini
Collection	fixed_size, semantic
Image vector	clip, clip_finetuned
Reranker	False, True

Tổng cộng:

$$2 \times 2 \times 2 \times 2 = \mathbf{16 \text{ cấu hình}}$$

Pipeline truy hồi

- 1 Từ output refine, tạo gói truy vấn gồm:
 - `text_queries`: claim đã chuẩn hoá, semantic queries, claim atoms, verification targets;
 - `keyword_query`: keywords và verification targets;
 - `visual_queries`: visual queries và visible evidence.
- 2 Truy hồi trong Qdrant theo ba nhánh:
 - text dense với Vietnamese bi-encoder;
 - text sparse với sparse vector;
 - image lane với CLIP hoặc CLIP fine-tuned.
- 3 Hợp nhất ứng viên bằng weighted Reciprocal Rank Fusion.
- 4 Nếu bật reranker, dùng ViRanker để tăng điểm các ứng viên text.
- 5 Tách kết quả thành hai lane: text và image, rồi lấy top-k.

Cách xác định một hit

Text/source hit

Một retrieved text được xem là đúng nguồn nếu URL sau chuẩn hoá khớp với `text_evidences_url`.

Text evidence hit

Nếu URL không khớp, hệ thống so khớp token giữa retrieved text và gold text evidence. Hit khi:

$$\text{coverage} \geq 0.60 \quad \text{hoặc} \quad F_1 \geq 0.45$$

Image evidence hit

Retrieved image được xem là đúng khi `image_path` sau chuẩn hoá khớp với `image_evidence_path`.

Metric đánh giá

Với mỗi claim, metric được tính trên top-k của text lane và image lane, sau đó lấy trung bình trên toàn bộ claim.

- **Source Hit@k**: có ít nhất một URL đúng trong top-k của text hoặc image lane.
- **Evidence Hit@k**: có ít nhất một text evidence hit hoặc image exact hit trong top-k.
- **MRR@3**: nghịch đảo rank của hit đầu tiên trong top-3.

$$\text{Hit@}k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\exists \text{ hit trong top } k]$$

$$\text{MRR@3} = \frac{1}{N} \sum_{i=1}^N \begin{cases} 1/r_i, & r_i \leq 3 \\ 0, & \text{không có hit trong top-3} \end{cases}$$

Các file kết quả được xuất ra

- `metrics_summary.csv`: metric trung bình của từng cấu hình.
- `best_combinations_by_metric.csv`: cấu hình tốt nhất theo từng metric.
- `claim_metrics_long.csv`: metric chi tiết theo từng claim.
- `retrieval_results_long.csv`: từng bằng chứng được truy hồi, rank, score, branch và trạng thái hit.
- `top3_urls_long.csv`: top-3 URL/text item/image item cho từng claim.
- `by_experiment/`: bản tách riêng cho từng cấu hình thí nghiệm.

Kết quả metrics được xuất ra

Refiner	Collection	Image vector	Reranker	Text Source Hit			Image Source Hit			MRR@3
				@3	@10	@20	@3	@10	@20	
gemini-2.5-flash	fixed_size	clip	False True	0.779 0.821	0.878 0.889	0.901 0.909	0.023 0.023	0.039 0.039	0.049 0.049	0.705 0.762
		clip_finetuned	False True	0.779 0.821	0.878 0.889	0.901 0.909	0.008 0.008	0.014 0.014	0.022 0.022	0.704 0.761
	semantic	clip	False True	0.776 0.832	0.868 0.894	0.901 0.917	0.023 0.023	0.039 0.039	0.049 0.049	0.692 0.773
		clip_finetuned	False True	0.776 0.832	0.868 0.894	0.901 0.917	0.008 0.008	0.014 0.014	0.022 0.022	0.690 0.772
gpt4o_mini	fixed_size	clip	False True	0.778 0.815	0.871 0.881	0.894 0.901	0.018 0.018	0.028 0.028	0.039 0.039	0.702 0.758
		clip_finetuned	False True	0.778 0.815	0.871 0.881	0.894 0.901	0.005 0.005	0.009 0.009	0.021 0.021	0.700 0.756
	semantic	clip	False True	0.768 0.826	0.865 0.889	0.896 0.905	0.018 0.018	0.028 0.028	0.039 0.039	0.675 0.761
		clip_finetuned	False True	0.768 0.826	0.865 0.889	0.896 0.905	0.005 0.005	0.009 0.009	0.021 0.021	0.674 0.760
raw_claim	semantic	clip_finetuned	True	0.825	0.882	0.899	0.001	0.002	0.002	0.763

Bảng lấy từ retrieval_eval_outputs/metrics_summary.csv và retrieval_eval_raw_outputs/metrics_summary.csv; mỗi câu hình được đánh giá trên 1293 claim, số liệu được làm tròn 3 chữ số thập phân. MRR@3 là source_mrr_at_3.

Raw claim: evidence-level metrics

Retrieval input	Text Evidence Hit			Image Exact Hit			Evidence MRR@3
	@3	@10	@20	@3	@10	@20	
Raw claim	0.924	0.951	0.958	0.000	0.000	0.000	0.886

Các số liệu được làm tròn 3 chữ số thập phân từ raw metrics summary; không thay đổi cấu trúc file CSV sinh ra từ notebook.

Đánh giá verdict của judge

Label	Precision	Recall	F1	Support
supported	0.946	0.803	0.869	432
refuted	0.658	0.905	0.762	431
nei	0.787	0.609	0.687	430
Accuracy			0.773	1293
Macro avg	0.797	0.772	0.772	1293
Weighted avg	0.797	0.773	0.772	1293

Kết quả lấy từ file `factchecking_metrics_*full.csv` trong `judge_outputs_openrouter`.

Confusion matrix của judge

Gold \ Pred	supported	refuted	nei
supported	347	47	38
refuted	8	390	33
nei	12	156	262

Lỗi lớn nhất là `nei` bị dự đoán thành `refuted`: 156 trường hợp. Điều này cho thấy judge có xu hướng diễn giải bằng chứng thiếu/không đủ kết luận thành bằng chứng phản bác trực tiếp.

LLM-as-a-judge cho explanation

- Evaluator: GPT-4o mini.
- Input: claim, gold label, model verdict, gold reason, generated explanation.
- Mỗi explanation được chấm 5 tiêu chí trên thang 1–5:
 - factual consistency;
 - verdict alignment;
 - completeness;
 - Vietnamese clarity;
 - no hallucination.
- Nhận tổng hợp:
 - pass: overall score ≥ 4.0 và không tiêu chí nào dưới 3;
 - borderline: overall score ≥ 3.0 nhưng chưa đạt pass;
 - fail: overall score < 3.0 hoặc có mâu thuẫn nghiêm trọng.

Kết quả LLM-as-a-judge cho explanation

Label	Count	Rate
pass	1083	0.838
borderline	65	0.050
fail	145	0.112

Metric	Mean
factual consistency	4.395
verdict alignment	4.525
completeness	3.993
Vietnamese clarity	4.829
no hallucination	4.766
overall score	4.465

Kết quả lấy từ `explanation_llm_judge_metrics_gpt4o_mini__gemini-2.5-flash__...__full.csv`; số dòng đánh giá: 1293.

- Cấu hình tốt nhất theo `source_hit_at_3`: Gemini 2.5 Flash + semantic collection + CLIP + reranker, đạt **0.833**.
- Cấu hình tốt nhất theo `evidence_hit_at_3`: GPT-4o mini + semantic collection + CLIP/CLIP-FT + reranker, đạt **0.922**.
- Reranker cải thiện rõ rệt nhóm cấu hình đứng đầu: các kết quả top đều là `reranker=True`.
- Collection semantic tốt hơn `fixed_size` trên cả source hit và evidence hit.
- Image exact hit còn thấp; phần lớn chất lượng top-3 đến từ text retrieval.

Kết luận thực nghiệm

- Pipeline truy hồi đa nhánh kết hợp dense, sparse và visual retrieval đạt hiệu quả cao cho truy hồi bằng chứng văn bản.
- Cấu hình nên ưu tiên cho hệ thống hiện tại:

`semantic collection + CLIP + reranker`

- Nếu mục tiêu tối ưu source URL chính xác, Gemini 2.5 Flash là refiner tốt nhất trong thí nghiệm.
- Nếu mục tiêu tối ưu evidence-level hit, GPT-4o mini cho kết quả nhỉnh hơn ở `evidence_hit_at_3`.